

Introducción al Análisis de Datos

Clase 2 - Herramientas



Índice

- ✓ Roles
- ✓ Tecnologías
- ✓ ETL
- ✓ Enfoques
- ✓ Data Warehouse
- ✓ Data Lake
- ✓ Actividad grupal

Avisos

✓ **Confirmar alta en CVG**

- Si no están: mail a gines@frsn.utn.edu.ar

✓ **Confirmar estado de inscripción a la materia por sysacad**

- Caso contrario: Confección de nota solicitando inscripción tardía
- Sin inscripción no podrán rendir exámenes.

Roles y Herramientas

Roles y Herramientas de Datos



Data Engineer

Diseña y construye la infraestructura para el flujo de datos.

Almacenamiento

Snowflake, BigQuery, Databricks, NoSQL

Procesamiento

Apache Spark

Orquestación y Streaming

Airflow, dbt, Apache Kafka



Data Scientist

Crea modelos predictivos y experimenta para el futuro.

Análisis y ML

Python (Pandas, NumPy), Scikit-learn

Deep Learning

TensorFlow, PyTorch

MLOps y Estadística

MLflow, R, RStudio



Data Analyst

Examina datos históricos para decisiones operativas.

Business Intelligence

Power BI, Tableau, Looker Studio

Hojas de Cálculo

Microsoft Excel, Google Sheets

Consultas

SQL (DBeaver, pgAdmin)

Tecnologías



Tecnologías

El poder tener datos para la explotación es un camino en el cual intervienen multiples herramientas. El objetivo para la clase de hoy es ver cuales son y qué nos aportan cada una de ellas.

Las podemos clasificar según su funcionalidad

- ✓ **Bases de datos**
- ✓ **ETL**
- ✓ **Visualización**
- ✓ **Lenguajes de programación**



Bases de datos

Para poder analizar nuestros datos, necesitamos que estén almacenados en algún **sistema**.

Bases de datos

1. **Conjunto de datos relacionados y organizados** de tal manera que puedan responder a un proposito especifico.
2. Permiten organizar los datos con metodos eficientes para obtener la información requerida y crear reglas para que se **almacenen de forma correcta y consistente**.
3. El language que permite obtener datos de una Base de Datos se llama **SQL** (Structured Query Language)

Tecnologías - Bases de datos

Estructurada

Sistemas que permiten que la información pueda ser gestionada por personas o aplicaciones.



No estructurada




Tecnologías - Visualización

Visualización de datos



Detecta tendencias, patrones y valores atípicos en los datos.



Bibliografía
recomendada

Herramientas más populares



Tecnologías - Lenguajes de programación

Los lenguajes de programación permiten **procesar, analizar y modelar los datos** de forma ágil y flexible.

Son especialmente diseñados para ser más eficientes en el análisis que los lenguajes tradicionales (C++, C, Java, etc.).



Python

Versátil y consolidado como el estándar principal en el mercado actual.



R

Especializado en el análisis estadístico profundo y modelado de datos.



Julia

Diseñado específicamente para computación científica de alto rendimiento.

ETL

—

Tecnologías - ETL

Cómo se mueven y preparan los datos



Proceso para **extraer, transformar y cargar** (Extract, Transform and Load) los datos desde sistemas operaciones hasta entornos analíticos.

Herramientas ETL más usadas



Informatica



Azure Data Factory



talend



SAP BusinessObjects



+ a b l e a u
p r e p



Microsoft
SQL Server

ETL



Extraer

Tomamos los datos desde distintas fuentes:

- Bases de datos
- APIs / sistemas externos
- Archivos (Excel, CSV)



Transformar

Preparamos los datos para que tengan sentido:

- Limpieza
- Unificación
- Validaciones
- Cálculos




Carga (Load)

Guardamos los datos listos para análisis:

- Data Warehouse
- Modelos de datos
- Tablas finales


👉 Sin ETL, los datos no son confiables ni útiles para analizar

Cómo fluye la información en un proceso ETL



Transformamos datos dispersos en información útil para la toma de decisiones

¿Cómo se ve un ETL?




Cómo se ve un ETL

```
CREATE PROCEDURE sp_ETL_Ventas
AS
BEGIN
    -- 1. EXTRACT (Origen) y 2. TRANSFORM (Limpieza/Cálculo)
    INSERT INTO FactVentas (FechaKey, ProductoID, Total, FechaCarga)
    SELECT
        CAST(FORMAT(Fecha, 'yyyyMMdd') AS INT), -- Transform: Formato Fecha
        ISNULL(ProductoID, 0), -- Transform: Limpieza Nulos
        (Cant * Precio) - Desc, -- Transform: Regla de Negocio
        GETDATE() -- Metadato
    FROM Staging_Ventas WHERE Procesado = 0;

    -- 3. LOAD / CIERRE (Control de flujo)
    UPDATE Staging_Ventas SET Procesado = 1 WHERE Procesado = 0;
END;
```

Cómo se ve un ETL



Cómo se ve un ETL

Consultas [8]

Calendar

Category

Customers

Flags

Geography

Products

Sales

Subcategory

123 Geography Id	A ^B C Country	A ^B C Region	A ^B C City
1	1 France	Auvernia-Ródano-Alpes	Grenoble
2	2 France	Auvernia-Ródano-Alpes	Lyon
3	3 France	Bajo Rin	Estrasburgo
4	4 France	Córdega	Ajaccio
5	5 France	Isla de Francia	París
6	6 France	Normandia	Caen
7	7 France	Normandia	Ruán
8	8 France	Nueva Aquitania	Burdeos
9	9 France	Occitania	Montpellier
10	10 France	Occitania	Toulouse
11	11 France	Provenza-Alpes-Costa Azul	Aviñón
12	12 France	Provenza-Alpes-Costa Azul	Marsella
13	13 France	Provenza-Alpes-Costa Azul	Niza
14	14 Germany	Baden-Wurtemberg	Stuttgart
15	15 Germany	Berlin	Berlin
16	16 Germany	Hamburg	Hamburg
17	17 Ireland	Dublin	Dublin
18	18 Ireland	Cork County	Cork
19	19 Italy	Apulia	Bari

Configuración de la consulta

PROPIEDADES

Nombre

Geography

Todas las propiedades

PASOS APLICADOS

Origen

Navegación

Encabezados promovidos

X Tipo cambiado

Mapa de herramientas



Los **datos** necesitan transformarse antes de generar **valor**

ETL - Extracción de datos

Cómo se obtienen los datos desde origen



Extracción total → Trae todos los datos cada vez
Se extrae todo lo que cumple las reglas definidas.

Todo

ID	Fecha	Venta
1	01/01	100
2	02/01	150
3	03/01	200




Incremental → Trae solo lo nuevo o modificado
Compara con extracciones anteriores.

ID	Fecha	Venta
1	01/01	100
2	02/01	150
3	03/01	200




Automática (eventos) → El sistema avisa cuando hay cambios
Webhooks / APIs / notificaciones.

Nuevo registro 
ID: 4 | 04/01 | 180



Continua (streaming) → Flujo constante de datos en tiempo real
La fuente envía datos continuamente.



ETL - Transformación datos

¿Qué buscamos?

Convertir datos crudos en información **confiable y usable**.

Etapas clave:



Limpieza y calidad → eliminar errores, duplicados, inconsistencias



Estandarización → formatos, unidades, dominios



Consolidación → unir, dividir y reorganizar datos



Enriquecimiento → cálculos, nuevos campos, contexto adicional



La transformación es la etapa más crítica del ETL por su complejidad y volumen de reglas.

ETL - Carga de datos

Carga: Donde los datos se vuelven utilizables

- La carga define **donde** y **como** se almacenan los datos
 - Datawarehouse, Data Lake o herramientas como Power BI
- No es solo “guardar”: Implica optimizar, estructurar y preparar los datos para su uso.
- En la práctica, la empresas automatizan este proceso mediante jobs o “cadenas” que ejecutan procesos periodicos (Semanal, diario, mensual, etc.)



Enfoques

Enfoques de arquitectura de Data Warehouse

01

¿Hay una sola manera de que nuestra compañía pueda acceder a los datos?

02

¿Solo el equipo de IT debería acceder a los datos?

03

¿Qué “autoservicio” se espera de las áreas no técnicas?

Responder esto nos ayudará a definir un modelo de arquitectura a la hora de implementar soluciones basadas en datos.

¿Cómo acceden las áreas a los datos?

Modelo 1: Tradicional (IT Centralizado)



IT controla el acceso a los datos

- Procesos estructurados (ETL, DW)
- Mayor control y calidad
- Menor velocidad de respuestas
- Requiere roles técnicos (IT, Data Engineer, etc)
- Casos típicos: Bancos, TeleCol. Retail, energía, etc. (grandes volúmenes)

Modelo 2: Self-Service (negocio autónomo)



Usuarios acceden directamente a los datos

- Herramientas de BI (Power BI, Tableau, etc.)
- Mayor velocidad y flexibilidad
- Riesgo de inconsistencia si no hay gobernanza.
- Usuarios típicos: Analistas de negocio, “no técnicos”
- Uso más extensivo a todas las áreas

Data Warehouse



El almacén de los datos



Orientado a la organización.

Contiene información relevante para el negocio, centrado en las actividades del rubro: Ventas, producción, clientes, etc.



Datos Integrados

Reune los datos de distintos sistemas fuentes (ERP, web, encuestas, etc.) que se normalizan y combinan.



Variables en el tiempo


Almacena datos periodicos con un desfase temporal, como “fotos” mensuales o anuales.



No volátil.


Los datos no se alteran: Solo se incrementan.
Historicos de 2 a 10 años que permanecen inalterados

¿Cómo se ve esto?




¿Cómo se ve esto?

Finalizado mi ETL y almacenados los datos en el DWH, me conecto con mi herramienta de visualización **para comenzar el análisis.**



SAP S/4 HANA



DWH: Factores de éxito vs Desafíos

Factores de éxito

- Integra multiples fuentes (internas + externas)
- Información relevante para el negocio
- Datos consistentes y confiables (calidad)
- Acceso directo para usuarios
- Escalable (usuarios + volumen)

Desafíos

- Alto costo inicial
- Alto costo de Mantenimiento
- Cambios constantes (negocio, fuentes, tecnología)
- Control de calidad de datos
- Complejidad de la integración

Data Lake

Data Lake

Un lago de datos (Data Lake) es un depósito de datos almacenados en su formato natural, “**en bruto**”, tal como se los almacena en las aplicaciones que los generan.

Principales características



01. Escalabilidad

Capacidad de crecer al ritmo del negocio, soportando grandes volúmenes de datos sin fricción.



02. Gobierno del dato

Conocer qué datos existen, su origen y calidad mediante catálogos y metadatos.



03. Orquestación

Automatización de la carga y consumo de datos, asegurando procesos consistentes.



04. Acceso ágil

Disponibilidad de datos en su formato original, facilitando consultas rápidas y exploración.

DWH: Factores de éxito vs Desafíos



Data Lake

- Repositorio centralizado de datos
- Puede estar on-premise o en la nube
- Permite almacenar grandes volúmenes en distintos formatos (estructurados y no estructurados)
- Bases para análisis y tomas de decisiones



Data Swamp

- Data Lake sin gestión ni control
- Datos desordenados o de baja calidad
- Difícil de usar para los usuarios
- Pierde valor para el negocio


No alcanza con **tener** los datos, hay que **gestionarlos** para que aporten valor.

Diferencia de enfoques

ETL → Transform BEFORE



ELT → Transform AFTER



ETL (Data Warehouse)

- Datos estructurados
- Transformación previa
- Optimizado para análisis

ELT (Data Lake)

- Datos en bruto
- Transformación posterior
- Optimizado para analítica avanzada

Actividad

Actividad



1. Descargar el dataset con transacciones bancarias
2. Listar problemas del mismo
3. Proponer transformaciones

Fin

—