



Introducción al Análisis de Datos


Semana 3




Distribución de Huéspedes por Habitación




9 Huéspedes habituales pagando \$50 USD • **1 Penthouse** pagando \$1,000 USD



Distribución de Huéspedes por Habitación



9 Huéspedes habituales pagando \$50 USD • **1 Penthouse** pagando \$1,000 USD



¿Cuál debería ser el precio representativo?

Consecuencias de la Media Aritmética

Métrica Tradicional

Media Aritmética

CÁLCULO:

$$(9 \times \$50 + \$1,000) / 10 = \underline{\$145 \text{ USD}}$$

El Impacto en Negocio

Tarifa Fija de \$145



Expulsión del 90% de Clientes

La tarifa estándar de \$50 USD migra a la competencia.



Subestimación del Cliente VIP

Dejas de capturar los \$1,000 USD de quien busca una suite.



RESULTADO: Quiebra por precios irrealistas y pérdida masiva de ocupación.

El Peligro de los Promedios

Distribución de Tarifas

Un solo huésped atípico distorsiona la métrica central.



Métrica Engañosa (Promedio) ✗

\$145 USD

Métrica distorsionada por un solo valor atípico. (outlier)

Métrica Correcta (Mediana) ✓

\$50 USD

Refleja la verdadera masa y realidad de los clientes.


Impacto: Base segura y realista para definir precios lógicos.

Introducción al Análisis de Datos

Estadística Descriptiva aplicada en Power BI

Población

- Totalidad de elementos
(finita o infinita)




Población

- Totalidad de elementos (finita o infinita)

Muestra

- Subconjunto representativo y adecuado



Población


- Totalidad de elementos (finita o infinita)

Muestra

- Subconjunto representativo y adecuado

UNIDAD ELEMENTAL

- Cada elemento individual (ej. una fila en una tabla de base de datos)



CLASIFICACIÓN DE VARIABLES

Las variables se clasifican según el tipo de valores que pueden tomar en su análisis.

CUALITATIVAS • Cualidades o Categorías

CUANTITATIVAS • Valores Numéricos

Nominales

Sin orden natural entre sus categorías.

Ejemplos:

- Lenguaje de programación (Python, Java)
- Sistema operativo (Linux, macOS)
- Estado de ticket (Abierto, Cerrado)

CLASIFICACIÓN DE VARIABLES

Las variables se clasifican según el tipo de valores que pueden tomar en su análisis.

CUALITATIVAS • Cualidades o Categorías

CUANTITATIVAS • Valores Numéricos

Nominales

Sin orden natural entre sus categorías.

Ejemplos:

- Lenguaje de programación (Python, Java)
- Sistema operativo (Linux, macOS)
- Estado de ticket (Abierto, Cerrado)

Ordinales

Existe un orden o jerarquía definida.

Ejemplos:

- Prioridad de un ticket (Baja, Media, Alta)
- Nivel de satisfacción (Bajo, Alto)
- Ranking de desempeño (1º, 2º, 3º)

CLASIFICACIÓN DE VARIABLES

Las variables se clasifican según el tipo de valores que pueden tomar en su análisis.

CUALITATIVAS • Cualidades o Categorías

Nominales

Sin orden natural entre sus categorías.

Ejemplos:

- Lenguaje de programación (Python, Java)
- Sistema operativo (Linux, macOS)
- Estado de ticket (Abierto, Cerrado)

Ordinales

Existe un orden o jerarquía definida.

Ejemplos:

- Prioridad de un ticket (Baja, Media, Alta)
- Nivel de satisfacción (Bajo, Alto)
- Ranking de desempeño (1º, 2º, 3º)

CUANTITATIVAS • Valores Numéricos

Discretas

Valores enteros y contables (conteo).

Ejemplos:

- Commits en un repositorio (12, 15, 30)
- Errores en un build (0, 1, 2)
- Usuarios conectados (150, 420)

CLASIFICACIÓN DE VARIABLES

Las variables se clasifican según el tipo de valores que pueden tomar en su análisis.

CUALITATIVAS • Cualidades o Categorías

Nominales

Sin orden natural entre sus categorías.

Ejemplos:

- Lenguaje de programación (Python, Java)
- Sistema operativo (Linux, macOS)
- Estado de ticket (Abierto, Cerrado)

Ordinales

Existe un orden o jerarquía definida.

Ejemplos:

- Prioridad de un ticket (Baja, Media, Alta)
- Nivel de satisfacción (Bajo, Alto)
- Ranking de desempeño (1º, 2º, 3º)

CUANTITATIVAS • Valores Numéricos

Discretas

Valores enteros y contables (conteo).

Ejemplos:

- Commits en un repositorio (12, 15, 30)
- Errores en un build (0, 1, 2)
- Usuarios conectados (150, 420)

Continuas

Cualquier valor real dentro de un rango.

Ejemplos:

- Tiempo de ejecución (1.23s, 0.85s)
- Uso de memoria (128 MB, 256.4 MB)
- Cobertura de código (94.5%)

Asociación: Tipo de Variable Tipo de Columna

La correcta correspondencia entre la teoría estadística y el diseño de la base de datos.

TIPO DE VARIABLE (Estadística)

CUALITATIVA NOMINAL

Categorías sin orden natural o jerárquico.

CUALITATIVA ORDINAL

Categorías con un orden o jerarquía definida.

CUANTITATIVA DISCRETA

Conteos numéricos que toman valores enteros.

CUANTITATIVA CONTINUA

Mediciones que pueden contener infinitos decimales.

TIPO DE COLUMNA EN TABLA (Base de Datos)

TEXT / STRING (VARCHAR)

Columna: **lenguaje** Ej.: "Python", "Java", "Go"

TEXT / CATEGORICAL ORDINAL

Columna: **prioridad** Ej.: "Baja", "Media", "Alta"

INTEGER (INT)

Columna: **errores** Ej.: 0, 3, 1, 8 (conteo de eventos)

FLOAT / DECIMAL (NUMERIC)

Columna: **tiempo_ejec_s** Ej.: 1.23, 0.85, 2.10



REGLA CLAVE: Entender el tipo de variable permite elegir el tipo de columna de base de datos adecuado, optimizando el almacenamiento y permitiendo aplicar las técnicas estadísticas correctas.

Medidas de Tendencia Central, Dispersión y Posición

Clasificación de métricas estadísticas fundamentales y su interpretación práctica.

Tendencia Central


Indican el centro de la distribución de los datos.

Métricas:

Media ($\bar{x}$), Mediana ($\tilde{M}$), Moda ($\hat{M}$)

Concepto Clave:

Media: Punto de equilibrio numérico.



Dispersión


Indican la variabilidad o extensión de los datos.

Métricas:

Rango, Varianza, Desviación Estándar (σ)

Concepto Clave:

Desviación Estándar: Agrupación respecto al centro.



Posición


Indican la ubicación de valores específicos.

Métricas:

Cuartiles (Q_1, Q_2, Q_3), Deciles, Percentiles

Concepto Clave:

Cuartiles: Dividen en 4 partes ($Q_2 =$ Mediana).



EJEMPLO EN DESARROLLO DE SOFTWARE: TIEMPOS DE RESPUESTA

- **Central:** Medir el tiempo promedio o la mediana de latencia para conocer el comportamiento estándar.
- **Dispersión:** El rango (diferencia entre respuesta más rápida y más lenta) indica la consistencia de los servidores.
- **Posición:** Usar percentiles de éxito (como p95 o p99) para evaluar la experiencia de la gran mayoría de los usuarios.

Práctica





Práctica Guiada: Caso de Estudio

Contexto y Objetivo

Una empresa hotelera desea estudiar el comportamiento de sus reservas para identificar patrones asociados a la cancelación de estadias.

Establecimientos bajo análisis:

- **Hoteles Urbanos**
- **Hoteles tipo Resort**

Datos

El dataset consolidado incluye múltiples variables de comportamiento y transaccionales:

- **ID de la reserva:** Clave primaria
- **Leadtime:** Anticipación (días) con las que se hace la reserva
- **Transacción:** Canal de reserva y tarifa promedio por noche.
- **Historial:** Registro de cancelaciones previas y estado final.

Datos del Proyecto

Estructura del Dataset

25k

Registros / Reservas

32

Variables

Fuente de Datos

Dataset 'hotel booking TPI grupo C.csv'

Variables Clave Analizadas



is_canceled

Estado de la reserva (0 = efectiva, 1 = cancelada)



lead_time

Días de anticipación de la reserva



adr

Tarifa Diaria Promedio (USD)

Métodos: Análisis de Frecuencias (Variable Categórica)

Configuración

Variable de Interés

`is_canceled`

Método Aplicado

Cálculo de Frecuencias Absolutas y
Relativas

Visualización Representada


Gráfico de Barras

Resultados Clave

62.96% — Reservas Efectivas



37.04% — Reservas Canceladas



Las reservas efectivas superan a las canceladas, pero el volumen de cancelaciones es significativo y requiere atención estratégica.

Métodos: Tendencia Central (Variable Cuantitativa)

Configuración

Variable de Interés

lead_time (Anticipación)

Método Aplicado

Cálculo de Media, Mediana y Moda

Visualización Representada

Histograma con líneas de tendencia

Conclusión Parcial:

La **media > mediana** revela una **asimetría a la derecha**, donde pocos clientes reservan con mucha antelación, "jalando" el promedio. La mediana es más representativa del comportamiento "típico".

Resultados Clave

Moda


0 días

Mediana

68.5 días

Media (Promedio)

102.6 días



¿Media o Mediana? Criterios de Elección según el Sesgo



1. Si Media > Mediana

Sesgo a la Derecha (Positivo)

Los valores atípicos altos arrastran la media hacia arriba.

★ Toma la MEDIANA si...

Buscas el caso típico (Evita extremos)

Ejemplo Salarios: Si 9 ganan \$1,000 y uno gana \$11,000, la mediana (\$1,000) es lo real; la media (\$2,000) confunde.

Σ Toma la MEDIA si...

Cálculos posteriores o impacto total

Necesario para varianza, proyecciones o para asegurar un reparto equitativo real de recursos totales.



2. Si Media < Mediana

Sesgo a la Izquierda (Negativo)

Los valores inusualmente bajos arrastran la media hacia abajo.

★ Toma la MEDIANA si...

Ignorar anomalías bajas (Para la mayoría)

Ejemplo Mortalidad: Muertes tempranas por accidente bajan la media, pero la mediana describe la expectativa típica.

Σ Toma la MEDIA si...

Medir pérdidas o caídas totales

Ejemplo Rendimiento: Si 3 alumnos sacan 0 en un examen fácil, la media refleja el verdadero impacto en el aula.

Anatomía del Boxplot

Guía visual de interpretación y componentes

Q1 (Primer Cuartil)

Percentil 25. El 25% de los datos tiene un valor menor o igual.

Mediana (Q2)


Línea central divisoria. Divide la muestra exactamente a la mitad.

Q3 (Tercer Cuartil)

Percentil 75. El 75% de los datos se ubica por debajo.

IQR (Rango Intercuartílico)

Ancho de la caja ($Q3 - Q1$). Muestra la dispersión del 50% central.



Bigotes (Whiskers)

Líneas que indican la variabilidad esperada fuera de la caja.

Mínimo y Máximo

Extremos que delimitan el rango de los valores válidos.

Outliers (Atípicos)

Puntos individuales aislados que representan anomalías.

Media (Promedio)

Punto o cruz. Su desviación de la mediana expone asimetría.

Análisis del Boxplot

Anatomía del Visual y Diagnóstico de Tarifas (ADR)

Métricas Clave

City Hotel

Mediana: **99 USD**

Q1 / Q3: **79 / 126**

IQR: **47 USD**

Máx: **372 USD**

Resort Hotel


Mediana: **75 USD**

Q1 / Q3: **50 / 126**

IQR: **76 USD**

Máx: **426 USD**

Distribución de Tarifas por Hotel (ADR)




Insights Clave (City Hotel)

- **El 50% central** de los clientes paga entre 68,25 USD y 126,00 USD por noche.
- **Mediana vs Promedio:** La mediana de 94,35 USD representa mejor la tarifa típica, evitando la distorsión de outliers extremos de hasta 426,25 USD.
- **Alerta de 0 USD:** Tarifas de 0 USD indican cortesías o errores a auditar 🚩

Anatomía del Boxplot


Guía visual de interpretación y componentes



Conclusiones Clave

1. Visión Holística


La comprensión de los datos requiere combinar múltiples medidas estadísticas (*media con mediana y desv. estándar*) y visualizaciones para entender el contexto.



2. Naturaleza de la Variable


El tipo de variable determina las herramientas de resumen más adecuadas y su correcta interpretación.

- **Categorica vs. Cuantitativa**



3. Impacto del Sesgo

En distribuciones asimétricas (*lead_time, adr*), la **mediana** es una medida de tendencia central más robusta y representativa que la media.



4. Oportunidades

El **37% de cancelaciones** representa una gran oportunidad de retención. La variabilidad en tarifas e inscripciones guía el marketing.



Fin

—