

UNIDAD N° 1

INTRODUCCIÓN
AL ANÁLISIS DE
DATOS

UNIDAD N° 1: INTRODUCCIÓN AL ANÁLISIS DE DATOS

REPASO BREVE DE ESTADÍSTICA DESCRIPTIVA

1. INTRODUCCIÓN

Este material recupera los conceptos de estadística descriptiva que se utilizarán durante Introducción al Análisis de Datos. No pretende reemplazar los apuntes completos de Probabilidad y Estadística ni repetir el desarrollo matemático de la unidad. Su función es ofrecer una guía breve para volver a activar ideas indispensables antes de comenzar a explorar datasets con herramientas computacionales.

Al trabajar con datos no alcanza con ejecutar código o aplicar funciones automáticas. Power BI, Python y R pueden calcular frecuencias, promedios, cuartiles o desvíos en pocos segundos, pero no deciden por nosotros si una medida es adecuada, si un resultado representa bien al conjunto o si una conclusión es razonable. Esa tarea requiere criterio estadístico.

En análisis de datos, la estadística descriptiva permite organizar valores, resumirlos, detectar patrones, reconocer comportamientos atípicos y formular preguntas nuevas. Por eso, el foco de este repaso está puesto en la interpretación: qué representa cada medida, cuándo conviene usarla, qué limitaciones tiene y cómo se relaciona con el problema que estamos estudiando.

Antes de avanzar, conviene mantener presentes algunas preguntas:

- ¿Qué representa cada fila del dataset?
- ¿Qué tipo de variable contiene cada columna?
- ¿La medida elegida tiene sentido para esa variable?
- ¿Hay valores extremos, faltantes o inconsistencias que puedan afectar el resultado?
- ¿El promedio describe a la mayoría de los casos?
- ¿Qué información adicional aporta la dispersión o la posición de los datos?
- ¿Qué conclusión puede sostenerse y cuál requeriría un análisis posterior?

2. EL CONTEXTO DE LOS DATOS

2.1. Población, muestra y unidad de análisis

La **población** es el conjunto total de elementos sobre los que queremos estudiar una característica. Puede estar formada por todas las ventas de una empresa, todos los usuarios de una aplicación, todos los tickets recibidos por un sistema o todas las ejecuciones posibles de un algoritmo bajo determinadas condiciones.

Una **muestra** es un subconjunto de esa población. Se utiliza cuando estudiar la totalidad resulta costoso, lento o imposible. Si pretendemos generalizar los resultados, la muestra debe representar razonablemente al conjunto del que proviene. Una muestra seleccionada solo entre casos cómodos o accesibles puede conducir a conclusiones sesgadas.

La **unidad de análisis** es cada elemento individual sobre el que se registran observaciones. En un dataset, con frecuencia cada fila representa una unidad, pero no siempre ocurre así: una fila puede representar una venta, un producto dentro de una venta, un cliente, una reserva, un día o una sucursal. Identificar esta unidad es fundamental porque define el significado de todas las variables.

2.2. Variables y tipos de datos

Una variable es una característica que puede tomar distintos valores entre las unidades de análisis. Si cada fila representa una persona, algunas variables podrían ser edad, provincia, nivel de satisfacción o cantidad de compras. Si cada fila representa una ejecución de un programa, podrían registrarse tiempo de ejecución, memoria utilizada, versión del algoritmo y presencia o ausencia de error.

La primera clasificación distingue variables cualitativas y cuantitativas:

Tipo de variable	Qué representa	Ejemplos	Análisis inicial habitual
Cualitativa nominal	Categorías sin orden	Sistema operativo, provincia, tipo de cliente	Frecuencias, porcentajes y moda
Cualitativa ordinal	Categorías con orden	Prioridad baja/media/alta, satisfacción	Frecuencias, porcentajes, moda y mediana según el caso
Cuantitativa discreta	Conteos	Cantidad de errores, accesos o ventas	Frecuencias y medidas descriptivas

Cuantitativa continua

Mediciones

Tiempo, peso, temperatura,
monto

Medidas descriptivas,
percentiles y distribución

Las variables cualitativas expresan categorías. En las nominales no existe un orden natural; en las ordinales sí existe una jerarquía, aunque no necesariamente una distancia numérica equivalente entre categorías. Las variables cuantitativas expresan cantidades: las discretas suelen surgir de conteos y las continuas de mediciones.

Que una columna esté codificada con números no la convierte automáticamente en cuantitativa. Por ejemplo, si 1 = Python, 2 = Java y 3 = C++, esos números son códigos de categorías. Calcular su media no tendría una interpretación válida.

2.3. Escalas de medición

La escala de medición indica qué operaciones e interpretaciones son válidas. Las escalas nominal y ordinal corresponden a variables categóricas. Las escalas de intervalo y de razón corresponden a variables cuantitativas.

Escal a	Característica	Ejemplo	Qué permite
Nominal	Clasifica sin ordenar	Lenguaje de programación	Contar, comparar proporciones e identificar la moda
Ordinal	Clasifica y ordena	Nivel de satisfacción	Ordenar, contar y usar medidas de posición con cautela
Intervalo	Las diferencias son significativas, pero el cero es convencional	Temperatura en °C	Comparar diferencias y calcular promedios
Razón	Tiene cero absoluto	Tiempo, cantidad, peso, monto	Comparar diferencias y proporciones

Identificar correctamente el tipo de variable y su escala evita aplicar herramientas que no tienen sentido. Para una variable nominal pueden calcularse frecuencias y porcentajes, pero no una media. Para una variable de razón, en cambio, puede afirmarse que un tiempo de 8 segundos es el doble que uno de 4 segundos porque el cero representa ausencia de duración.

3. ORGANIZACIÓN INICIAL DE LOS DATOS: FRECUENCIAS

Una tabla de frecuencias permite organizar los valores de una variable y responder preguntas básicas: ¿qué categorías aparecen?, ¿cuál es la más frecuente?, ¿qué proporción representa cada valor?, ¿cuántas observaciones se

acumulan hasta cierto punto? En Python o R estas tablas suelen obtenerse mediante funciones, pero su interpretación sigue siendo la misma.

3.1. Frecuencia absoluta y frecuencia relativa

La **frecuencia absoluta (fi)** indica cuántas veces aparece un valor o categoría. La suma de todas las frecuencias absolutas es igual al total de observaciones n.

La **frecuencia relativa (fr)** expresa qué proporción del total representa cada frecuencia absoluta.

$$fr = fi / n$$

Al multiplicar la frecuencia relativa por 100 se obtiene el porcentaje. Esta medida permite comparar grupos de distinto tamaño y evita que un recuento absoluto se interprete sin considerar la cantidad total de casos.

Prioridad	Frecuencia absoluta	Frecuencia relativa	Porcentaje
Baja	18	0,20	20 %
Media	42	0,47	46,7 %
Alta	25	0,28	27,8 %
Crítica	5	0,06	5,6 %
Total	90	1,00	100 %

En este ejemplo, la prioridad más frecuente es Media, con 42 casos. Sin embargo, la interpretación más completa es que representa aproximadamente el 46,7 % del total.

Informar porcentaje y cantidad ofrece una lectura más transparente.

3.2. Frecuencias acumuladas

La frecuencia acumulada se utiliza cuando los valores tienen un orden. Indica cuántas observaciones presentan un valor menor o igual que un determinado punto. La frecuencia relativa acumulada expresa esa acumulación como proporción o porcentaje.

Cantidad de errores	Frecuencia absoluta	Frecuencia acumulada	Frecuencia relativa acumulada
0	6	6	0,15
1	10	16	0,40
2	14	30	0,75
3	8	38	0,95
4	2	40	1,00

La frecuencia acumulada de 2 errores es 30: treinta módulos tuvieron 2 errores o menos. La frecuencia relativa acumulada correspondiente es 0,75: el 75 % de los módulos tuvo como máximo 2 errores. Este tipo de lectura es habitual cuando se analizan tiempos, cantidades, calificaciones o niveles ordenados.

3.3. Datos no agrupados y datos agrupados

Cuando una variable cualitativa o cuantitativa discreta presenta pocos valores distintos, cada valor puede mostrarse en una fila. En cambio, si una variable continua o una variable discreta posee muchos valores, conviene agrupar las observaciones en intervalos.

Un intervalo escrito como $[0, 2)$ incluye el 0 y excluye el 2; en símbolos, $0 \leq x < 2$. Esta convención evita que un mismo valor pertenezca a dos intervalos. La marca de clase es el punto medio del intervalo y funciona como valor representativo. La amplitud es la diferencia entre el límite superior y el límite inferior.

$$\text{Marca de clase} = (\text{límite inferior} + \text{límite superior}) / 2$$

En este repaso no es necesario reconstruir manualmente tablas agrupadas complejas. Lo importante es poder leerlas: identificar el intervalo más frecuente, interpretar porcentajes acumulados y reconocer qué proporción cumple o no un umbral de interés.

4. MEDIDAS DE TENDENCIA CENTRAL

Las medidas de tendencia central resumen un conjunto de datos mediante un valor que representa su centro. Las principales son la media, la mediana y la moda. No existe una medida universalmente mejor: la elección depende del tipo de variable, la forma de la distribución y la presencia de valores extremos.

4.1. Media aritmética

La media aritmética es el promedio. Se calcula sumando todos los valores y dividiendo por la cantidad de observaciones.

$$\bar{x} = \Sigma x_i / n$$

La media utiliza todos los datos, lo que constituye una ventaja cuando la distribución es relativamente equilibrada. Al mismo tiempo, esa característica la vuelve sensible a valores atípicos: una observación muy alta o muy baja puede desplazar el promedio y reducir su representatividad.

Consideremos los tiempos 4, 5, 6, 5 y 40 segundos. La media es 12 segundos. Sin embargo, cuatro de los cinco valores se encuentran entre 4 y 6. El valor 40 arrastra el promedio hacia arriba; por eso, informar la media sin revisar el resto de la distribución puede ser engañoso.

4.2. Mediana

La mediana es el valor que ocupa la posición central cuando los datos se ordenan de menor a mayor. Deja aproximadamente el 50 % de los valores por debajo y el 50 % por encima. Si la cantidad de datos es par, se toma el promedio de los dos valores centrales.

Para 4, 5, 5, 6 y 40, la mediana es 5. A diferencia de la media, no se desplaza de manera importante por la presencia del 40. Por eso suele describir mejor el centro en variables asimétricas o con valores extremos, como ingresos, montos de compra, duración de sesiones o tiempos de respuesta.

4.3. Moda

La moda es el valor o categoría que aparece con mayor frecuencia. Puede haber una moda, varias modas o ninguna moda definida. Es especialmente importante para variables cualitativas, donde la media no tiene sentido.

En el conjunto 4, 5, 5, 6 y 40, la moda es 5. En una variable como sistema operativo, la moda podría ser Windows; en tipo de cliente, podría ser Transient; en prioridad de un ticket, podría ser Media.

4.4. Comparación

Medida	Qué representa	Ventaja	Limitación principal
Media	Promedio aritmético	Usa todos los valores	Es sensible a valores extremos
Mediana	Valor central ordenado	Es resistente a valores extremos	No considera la magnitud de todos los valores
Moda	Valor o categoría más frecuente	Es válida para variables categóricas	Puede haber varias o no existir una única moda

Cuando media y mediana son cercanas, la distribución puede ser aproximadamente simétrica. Cuando difieren mucho, conviene investigar asimetría, valores atípicos o subgrupos con comportamientos distintos.


5. POSICIÓN, FORMA DE LA DISTRIBUCIÓN Y VALORES ATÍPICOS

5.1. Cuartiles y percentiles

Las medidas de posición indican dónde se ubica un valor dentro del conjunto ordenado. Los cuartiles dividen los datos en cuatro partes. El primer cuartil Q_1 deja el 25 % por debajo; Q_2 coincide con la mediana; Q_3 deja el 75 % por debajo.

Los percentiles dividen los datos en cien partes. El percentil P_k es el valor por debajo del cual se encuentra aproximadamente el k % de las observaciones. Por ejemplo, si el percentil 90 de un tiempo de respuesta es 2,5 segundos, aproximadamente el 90 % de las respuestas tarda como máximo 2,5 segundos.

Los percentiles son muy utilizados para establecer umbrales y analizar los casos más lentos, más grandes o más exigentes. Un promedio aceptable puede ocultar que un porcentaje pequeño de usuarios enfrenta tiempos muy elevados; por eso suelen revisarse P_{90} , P_{95} o P_{99} en contextos tecnológicos.



5.2. Forma y asimetría

La forma de una distribución orienta la selección de medidas. En una distribución aproximadamente simétrica, media, mediana y moda suelen ubicarse cerca. En una distribución con asimetría positiva, algunos valores grandes extienden la cola hacia la derecha y la media suele superar a la mediana. En una distribución con asimetría negativa, algunos valores pequeños extienden la cola hacia la izquierda y la media suele quedar por debajo de la mediana.

Forma aproximada	Relación habitual	Lectura orientativa
Simétrica	Media $\approx$ Mediana $\approx$ Moda	El centro está equilibrado
Asimetría positiva	Media > Mediana	Existen valores grandes que elevan el promedio
Asimetría negativa	Media < Mediana	Existen valores pequeños que reducen el promedio

Estas relaciones son orientativas. La forma debe confirmarse con la distribución de frecuencias y, más adelante, con gráficos. No corresponde clasificar una distribución solo por una diferencia pequeña entre dos medidas.

5.3. Valores atípicos

Un valor atípico u outlier es una observación que se aleja del comportamiento general. Puede ser un error de carga, un problema de medición, un caso real excepcional o un evento importante. Por eso no debe eliminarse automáticamente.

Antes de decidir qué hacer con una observación extrema, conviene preguntar:

- ¿El valor es posible dentro del contexto?
- ¿Existe evidencia de error de carga o medición?
- ¿Representa un caso real pero excepcional?
- ¿Pertenece a un subgrupo que debería analizarse por separado?
- ¿Modifica de manera importante la media o el desvío estándar?
- ¿Su eliminación cambiaría la conclusión del análisis?

Cuando existen valores extremos, la mediana y el rango intercuartílico suelen ofrecer una descripción más resistente que la media y el desvío estándar. Sin embargo, ambas parejas pueden informarse si se explican sus diferencias.

6. MEDIDAS DE DISPERSIÓN

Una medida de tendencia central no informa cuánto varían los datos. Dos conjuntos pueden tener la misma media y comportamientos muy distintos. Por ejemplo, 8, 9, 10, 11 y 12 tienen media 10; también 2, 6, 10, 14 y 18 tienen media 10. El segundo conjunto está mucho más disperso.

6.1. Rango

El rango es la diferencia entre el valor máximo y el mínimo.

$$R = x_{\max} - x_{\min}$$

Es fácil de calcular y ofrece una primera idea de la extensión total. Su limitación es que depende solamente de dos observaciones y puede aumentar mucho por un único valor extremo.

6.2. Varianza y desvío estándar

La varianza mide cuánto se alejan los valores respecto de la media, considerando los desvíos al cuadrado. Para una muestra se utiliza:

$$s^2 = \Sigma(x_i - \bar{x})^2 / (n - 1)$$

Como la varianza queda expresada en unidades cuadradas, suele interpretarse mediante el desvío estándar, que es su raíz cuadrada:

$$s = \sqrt{s^2}$$

El desvío estándar se expresa en la misma unidad que la variable. Un valor pequeño indica que las observaciones se concentran cerca de la media; un valor grande indica mayor variabilidad. Su magnitud siempre debe interpretarse en relación con la escala y el contexto.

Supongamos dos sistemas con tiempo promedio de 2 segundos. El Sistema A tiene un desvío de 0,2 segundos y el Sistema B de 1,5 segundos. Aunque comparten el mismo promedio, el primero es más estable; el segundo puede ofrecer experiencias muy diferentes entre usuarios.

6.3. Coeficiente de variación

El coeficiente de variación expresa el desvío estándar como porcentaje de la media y permite comparar dispersión relativa entre conjuntos con medias o unidades diferentes.

$$CV = (s / \bar{x}) \times 100$$

Si un conjunto tiene media 100 y desvío 10, su CV es 10 %. Si otro tiene media 10 y desvío 5, su CV es 50 %. Aunque el primer desvío es mayor en términos absolutos, el segundo conjunto es mucho más variable en relación con su promedio.

Atención, no existe una escala universal que permita clasificar todo CV como bajo, moderado o alto. La interpretación depende del fenómeno, del área y del nivel de estabilidad esperado.

6.4. Rango intercuartílico

El rango intercuartílico (RI o IQR) mide la extensión del 50 % central de los datos.

$$RI = Q3 - Q1$$

Como no depende del mínimo ni del máximo, es resistente a valores extremos. Por eso suele acompañar a la mediana. La pareja media-desvío estándar es adecuada para distribuciones relativamente simétricas; la pareja mediana-rango intercuartílico suele ser preferible en distribuciones asimétricas o con outliers.

Medida de centro	Medida de dispersión que suele acompañarla	Situación habitual
Media	Desvío estándar	Distribución aproximadamente simétrica y sin extremos dominantes
Mediana	Rango intercuartílico	Distribución asimétrica o con valores atípicos
Moda / frecuencias	Porcentajes por categoría	Variable cualitativa

7. ¿QUÉ MEDIDAS CONVIENE USAR?

La selección de medidas descriptivas depende del tipo de variable, la escala de medición, la forma de la distribución y la pregunta del análisis. Calcular todas las medidas disponibles no garantiza una mejor descripción; lo importante es elegir las que tengan sentido y explicarlas.

Situación	Medidas útiles	Evitar o interpretar con cautela
Variable nominal	Frecuencias, porcentajes y moda	Media, desvío y operaciones con códigos
Variable ordinal	Frecuencias ordenadas, porcentajes, moda y mediana según el caso	Promedios sobre códigos sin justificar
Cuantitativa aproximadamente simétrica	Media, desvío estándar, mínimo, máximo y cuartiles	Conclusiones basadas solo en el promedio
Cuantitativa asimétrica o con outliers	Mediana, cuartiles, percentiles y RI	Interpretar la media como valor típico sin compararla
Comparación entre escalas distintas	Coefficiente de variación, si la media es adecuada	Comparar solo desvíos absolutos

Una descripción completa combina distintas perspectivas. En variables cuantitativas suele ser útil informar: cantidad de observaciones, valores faltantes, mínimo, máximo, media, mediana, cuartiles y una medida de dispersión. En variables categóricas conviene informar categorías, frecuencias y porcentajes, además de revisar valores mal escritos o categorías duplicadas.

9. ERRORES FRECUENTES

9.1. Confundir códigos con cantidades

Una columna numérica puede representar categorías. Antes de calcular una media, hay que revisar el significado de los valores y el diccionario de datos.

9.2. Informar la media sin revisar la mediana y los extremos

La media puede estar desplazada por outliers. Conviene compararla con la mediana, los cuartiles, el mínimo y el máximo.

9.3. Interpretar el desvío sin mirar la escala

Un desvío de 2 unidades puede ser grande o pequeño según la media, la unidad y el fenómeno. Cuando corresponde, el CV ayuda a evaluar dispersión relativa.

9.4. Usar porcentajes sin informar la base

Decir “el 40 % de los casos” es incompleto si no se conoce el total. Siempre conviene indicar porcentaje y cantidad de observaciones.

9.5. Confundir descripción con explicación

Una diferencia entre grupos no demuestra causalidad. La estadística descriptiva identifica patrones que deberán analizarse con otras variables y métodos.

9.6. Ignorar datos faltantes, duplicados o inconsistentes

Una medida calculada sobre datos incompletos o mal registrados puede ser engañosa. Antes de interpretar, hay que conocer cuántos valores se utilizaron y qué problemas de calidad existen.

10. DEL RESUMEN ESTADÍSTICO AL ANÁLISIS EXPLORATORIO

La estadística descriptiva es una base del análisis exploratorio de datos (EDA). El EDA busca comprender el dataset antes de aplicar modelos o formular conclusiones definitivas. Entre sus preguntas iniciales se encuentran:

- ¿Cuántas observaciones y variables contiene el dataset?
- ¿Qué representa cada fila?
- ¿Qué tipo de variable es cada columna?
- ¿Hay valores faltantes, duplicados o inconsistencias?
- ¿Qué categorías son más frecuentes?
- ¿Cómo se distribuyen las variables numéricas?
- ¿La media y la mediana son similares?
- ¿Hay valores atípicos o subgrupos que requieren atención?
- ¿Qué medidas resumen mejor cada variable?
- ¿Qué nuevas preguntas aparecen a partir de los primeros resultados?

Estas preguntas preparan el camino para las visualizaciones, la limpieza de datos y los análisis posteriores. El objetivo de una primera exploración no es responder todo, sino comprender la estructura, reconocer problemas y orientar las siguientes decisiones.

11. GUÍA RÁPIDA DE INTERPRETACIÓN

11.1. Cuando observes una variable cualitativa

- Identificá sus categorías y verificá si tienen un orden natural.
- Revisá categorías mal escritas, duplicadas o poco frecuentes.
- Calculá frecuencias absolutas, frecuencias relativas y porcentajes.
- Identificá la moda o categoría más frecuente.
- Informá siempre la cantidad total de observaciones.

11.2. Cuando observes una variable cuantitativa

- Reconocé la unidad de medida y el rango posible.
- Revisá cantidad de datos válidos, mínimo y máximo.
- Compará media y mediana.
- Observá Q1, Q3 y percentiles relevantes.
- Interpretá el desvío estándar o el rango intercuartílico según la forma de la distribución.
- Buscá posibles valores atípicos y evitá eliminarlos sin explicación.
- Expresá el resultado en el contexto de la variable y del problema.

11.3. Antes de escribir una conclusión

- ¿Qué variable estoy analizando?
- ¿Qué representa cada observación?
- ¿La medida utilizada es válida para ese tipo de dato?
- ¿El resultado está expresado con su unidad o porcentaje?
- ¿La conclusión reconoce valores extremos, faltantes o limitaciones?
- ¿Estoy describiendo un patrón o intentando explicar una causa que todavía no fue demostrada?
- ¿Qué pregunta nueva habilita este resultado?

12. SÍNTESIS Y CIERRE

La estadística descriptiva permite organizar, resumir e interpretar datos. Las frecuencias muestran cómo se distribuyen categorías y valores. La media, la mediana y la moda describen el centro desde perspectivas diferentes. Los cuartiles y percentiles ubican observaciones dentro del conjunto. El rango, el desvío estándar, el coeficiente de variación y el rango intercuartílico permiten estudiar la variabilidad.

Estas herramientas se complementan. Un promedio sin dispersión puede ser insuficiente; una mediana sin cuartiles no muestra la extensión del 50 % central; un porcentaje sin cantidad total puede resultar engañoso. La elección debe responder al tipo de variable, a la forma de los datos y a la pregunta de análisis.