

Guía de Estudio — Parcial 1: Introducción al Análisis de Datos

Basada en: Clase 1 (El mundo de los datos), Clase 2 (Herramientas de BI), Clase 3 (Estrategias de medición), Clase 4 (Data Manipulation), Clase 5 (Estadística con PBI) y Resumen de Estadística Descriptiva.

1. El mundo de los datos (Clase 1)

Dato vs. Información

Concepto	Definición
Dato	Representación simbólica de un hecho. No tiene sentido semántico ni transmite un mensaje por sí solo.
Información	Conjunto de datos procesados y organizados que transmiten un significado, reducen la incertidumbre e incrementan el conocimiento.

- Cita clave: “Los datos son el nuevo petróleo” — Clive Humby.
- Ejemplo: los valores 20, 50, centímetros, -10 no significan nada aislados; procesados correctamente, informan una decisión.

Tipos de análisis de datos (4 niveles)

Nivel	Pregunta	Producto típico
Descriptivo	¿Qué pasó?	Reportes
Diagnóstico	¿Por qué pasó?	Dashboards interactivos
Predictivo	¿Qué pasará?	Modelos (basados en datos históricos)
Prescriptivo	¿Qué debería hacer?	Recomendaciones / automatización (simulaciones y optimizaciones)

Ciclo de vida de los datos

1. **Recolección:** identificar el origen y almacenar digitalmente.
2. **Mantenimiento:** revisar y procesar para garantizar calidad.
3. **Síntesis:** modelar según los indicadores requeridos.
4. **Uso:** explotación (reportes, informes, modelos).
5. **Publicación:** exponer el análisis para la toma de decisiones.
6. **Depuración:** detectar si la información requiere agregaciones, eliminaciones o cambios.

Cultura Data Driven

- **Características:** decidir en base a información, generar conocimiento, alcance en toda la organización, democratización de los datos, gobierno de datos, medición de riesgo e intangibles.
- **Impedimentos:** errores al armar el equipo, falta de habilidades de análisis, sesgos, miedo al cambio, desconfianza en los datos, problemas de adopción de las herramientas.

Historia

- **John Snow (Londres, 1854, barrio Soho):** el “primer detective de datos” — mapeó casos de cólera para identificar la fuente (bomba de agua). Ejemplo clásico de análisis de datos aplicado.

2. Herramientas de BI (Clase 2)

Roles del mundo de datos

Rol	Función	Herramientas
Data Engineer	Diseña y construye la infraestructura de flujo de datos	Snowflake, BigQuery, Databricks, NoSQL, Apache Spark, Airflow, dbt, Kafka
Data Scientist	Crea modelos predictivos y experimenta	Python (Pandas, NumPy), Scikit-learn, TensorFlow, PyTorch, MLflow, R
Data Analyst	Examina datos históricos para decisiones operativas	Power BI, Tableau, Looker Studio, Excel, SQL (DBeaver, pgAdmin)

Tecnologías (clasificación por funcionalidad)

1. **Bases de datos:** datos relacionados y organizados para un propósito. Se consultan con **SQL** (Structured Query Language). Pueden almacenar datos **estructurados** o **no estructurados**.
2. **ETL**
3. **Visualización**
4. **Lenguajes de programación:** Python (estándar del mercado, versátil), R (análisis estadístico profundo), Julia (computación científica de alto rendimiento).

ETL — Extract, Transform, Load

Etapas	Qué hace	Ejemplos
Extraer	Tomar datos de distintas fuentes	Bases de datos, APIs/sistemas externos, archivos (Excel, CSV)
Transformar	Preparar los datos para que tengan sentido (etapa más crítica)	Limpieza, unificación, validaciones, cálculos, estandarización, consolidación, enriquecimiento
Cargar	Guardar los datos listos para análisis	Data Warehouse, modelos de datos, tablas finales

- Sin ETL los datos **no son confiables ni útiles** para analizar.
- En la práctica se automatiza con jobs/cadenas periódicas (diario, semanal, mensual).

Enfoques de arquitectura

Modelo	Características
Tradicional (IT centralizado)	IT controla el acceso; procesos estructurados (ETL, DW); más control y calidad; menor velocidad; requiere roles técnicos. Típico: bancos, telecom, retail, energía (grandes volúmenes).
Self-Service (negocio autónomo)	Usuarios acceden directamente con herramientas de BI; más velocidad y flexibilidad; riesgo de inconsistencia sin gobernanza; usuarios “no técnicos”.

Data Warehouse (DWH)

Características (Inmon): 1. **Orientado a la organización** (ventas, producción, clientes). 2. **Datos integrados**: reúne y normaliza datos de distintos sistemas (ERP, web, encuestas). 3. **Variables en el tiempo**: guarda “fotos” periódicas. 4. **No volátil**: los datos no se alteran, solo se incrementan (históricos de 2 a 10 años).

- **Factores de éxito**: integra múltiples fuentes, información relevante, datos consistentes, acceso directo, escalable.
- **Desafíos**: alto costo inicial y de mantenimiento, cambios constantes, control de calidad, complejidad de integración.

Data Lake

- Depósito de datos en su **formato natural (“en bruto”)**, tal como los generan las aplicaciones.
- Características: escalabilidad, gobierno del dato (catálogos y metadatos), orquestación, acceso ágil.
- **Data Swamp** = Data Lake sin gestión ni control (datos desordenados, baja calidad, pierde valor). *No alcanza con tener datos, hay que gestionarlos.*

ETL vs ELT

ETL (Data Warehouse)	ELT (Data Lake)
Datos estructurados	Datos en bruto
Transformación previa a la carga	Transformación posterior
Optimizado para análisis	Optimizado para analítica avanzada

3. Estrategias de medición (Clase 3)

“Lo que no se mide, no se puede mejorar” — William Thomson Kelvin.

Data Analytics Journey (5 pasos)

1. Inmersión
2. **Estrategia de Medición** (KPIs, OKRs, dimensiones)
3. Implementación técnica
4. Análisis de información y obtención de resultados
5. Generación de conocimiento

Ciclo iterativo: **Medir** → **Analizar** → **Aprender** → **Mejorar**.

KPI (Key Performance Indicator)

4 pilares de un KPI efectivo: 1. **Específico**: un aspecto concreto a la vez. 2. **Medible**: cantidades realistas y cuantificables. 3. **Temporal**: frecuencia definida (diario, mensual, etc.). 4. **Relevante**: información crítica para el negocio.

- Los KPIs deben **informar, controlar, evaluar y ayudar a tomar decisiones**.
- Cada empresa/industria tiene indicadores propios. Ejemplos: % asistencia (educación), cantidad de viajes (plataforma de viajes), % suscriptores (streaming).

Dimensiones

Variables **cualitativas** que permiten agrupar, filtrar u ordenar métricas. Tres formas: 1. **Texto**: categorías, segmentos, sucursal (ej: chofer, región, categoría de producto). 2. **Booleanas**: Sí/No, Verdadero/Falso, 0/1 (ej: ¿viaje cancelado?). 3. **Tiempo**: fecha, año, trimestre (usadas con *time intelligence*).

En SQL: `SELECT COUNT(*) ... GROUP BY dimensión`.

OKRs (Objectives and Key Results)

- Metodología popularizada por **John Doerr** (años 90, libro *"Measure What Matters"*); usadas por Google, Spotify, Netflix, Amazon, LinkedIn.
- **Objetivo (O)**: cualitativo, inspirador, desafiante, corto y memorable.
- **Key Results (KR)**: métricas cuantitativas de progreso; **2 a 5 por objetivo**; atados a una unidad de tiempo.
- **Regla de oro**: un KR mide **impacto/valor (outcomes)**, **no** tareas o pasos metodológicos (outputs).
- ❌ "Extraer y limpiar datos", "Armar el dashboard" (son tareas).
- ✅ "Reducir cancelaciones del 14% al 5%", "Lograr 90% de adopción del dashboard".

Relación OKR–KPI: los KRs se miden en base a KPIs específicos. *"Sin métricas claras (KPIs), no hay resultados clave (KRs) verificables."*

Ventajas de los OKRs: relación con la meta, priorización, colaboración, comunicación, temporalidad.

Power BI (introducción)

Origen: límites de Excel → "Power Stack" (Power Pivot 2010, Power View 2011, Power Query 2013) → **Power BI Desktop 2015**.

Ecosistema: | Componente | Función | |—|—| | **Desktop** | Motor gratuito: conectar, modelar, visualizar (desarrollo) | | **Service** | SaaS para compartir reportes y seguridad (colaboración) | | **Mobile/Web** | Consumo desde cualquier dispositivo | | **Gateway** | Puente seguro para actualizar datos locales |

Flujo de trabajo: 1. Preparar (obtener/limpiar datos) → 2. Explorar → 3. Reportes → 4. Compartir.

Vistas de Power BI Desktop: Reporte, Datos, Relaciones. **Editor de consultas (Power Query)**: consultas, barra de transformaciones, pasos aplicados.

Conexión de datos: Excel (cada hoja puede ser una fuente), CSV/TXT (definir **delimitador** e **idioma** para ñ/acentos), configuración de orígenes de datos.

4. Data Manipulation (Clase 4)

"Garbage in, Garbage out": tus análisis serán tan buenos como tus datos.

Pilares de la calidad de datos

- **Precisión**: datos certeros y confiables.
- **Integridad**: información completa y consistente.
- **Oportunidad**: disponibilidad a tiempo.
- **Claridad**: formato interpretable para el negocio.

Procesos de procesamiento de datos

Proceso	Descripción	Ejemplo
Limpieza	Eliminar ruido, corregir inconsistencias	Duplicados, formatos de fecha (DD/MM vs MM/DD)
Transformación	Modificar/agregar datos para mejores conclusiones	Convertir moneda, agrupar edades en rangos
Integración	Compilar datos de distintas bases en un dataset	Unir CRM con Google Analytics

Estructura del modelo de datos

- **Dimensiones (entidades)**: fechas, clientes, transportes, empleados, productos (atributos descriptivos: ID, nombre, unidad de medida).
- **Hechos (eventos)**: ventas (ID factura, fecha, ID producto, ID cliente, importe total).
- Preguntas clave al explorar: **tipos de datos y unidades de medida**, **contexto** (qué explica cada variable, outliers, faltantes), **relaciones** (cómo se relacionan las tablas, transformaciones necesarias).

5 malas prácticas comunes

1. **Espacios fantasma**: ["Norte", " Norte ", "Norte "] duplican categorías → aplicar **Trim**.
2. **Hard-coding manual**: `if ID=15 then "VIP"` → usar **tabla de mapeo + Merge** en Power Query.
3. **Mezclar unidades**: sumar 100 USD + 100 ARS → normalizar moneda.
4. **Transformaciones manuales sobre el origen**: "Ventas_Final_v2_CORREGIDO.xlsx" → proceso ETL en Power Query.
5. **Sin documentación**: pasos genéricos (Paso1, Personalizado1) → **renombrar cada paso**.

Power Query — herramientas más usadas

- **Tipo de datos**: convertir el tipo de dato.
- **Reemplazar valores**: automatizar reemplazos.
- **Quitar columnas / Duplicar columna**.
- **Dividir columna**: separar por delimitador.
- **Columna condicional**: lógica igual a / contiene / mayor que.

⚠ Diferencia clave: **"Agregar columna"** crea información nueva; **"Transformar"** modifica la existente.

Flujo de limpieza típico (caso transacciones bancarias)

1. Quitar fila de encabezados mal puesta y **promover la primera fila a encabezado**.
2. Eliminar filas/columnas vacías.
3. Corregir columnas de texto sucio (status, card_type, city): - Opción A: **columna condicional** (lógica de corrección). - Opción B: **reemplazar valores** en la misma columna. - Opción C (más sofisticada): **tabla intermedia (staging) + Merge/Join** para mapear valores → mejor para mantenimiento con cargas periódicas.
4. Fechas/horas inconsistentes: **dividir columna** (fecha y hora), asignar formato, reemplazar errores por **null** (no perder el registro).
5. Columna numérica (amount): corregir formato texto ("," vs "."), convertir a número, **filtrar outliers y valores sin sentido** (0, -1), editar el código M si faltan operadores.
6. **Renombrar cada paso aplicado** → Cerrar y aplicar.

5. Estadística Descriptiva (Clase 5 + Resumen)

Caso motivador: el peligro de los promedios

Hotel: 9 huéspedes pagan \$50 y 1 penthouse paga \$1.000. - **Media = \$145** → distorsionada por el outlier → precio irreal, expulsa al 90% de clientes. - **Mediana = \$50** → refleja el cliente típico → base realista para precios.

Clasificación de variables

Tipo	Subtipo	Ejemplos	Columna típica (BD)	Análisis habitual
Cualitativa	Nominal (sin orden)	Sistema operativo, provincia, tipo de cliente	TEXT / VARCHAR	Frecuencias, %, moda
	Ordinal (con orden)	Prioridad baja/media/alta, satisfacción	TEXT / categorical ordinal	Frecuencias, %, moda, mediana
Cuantitativa	Discreta (conteo)	Commits, errores, usuarios conectados	INTEGER	Frecuencias, descriptivas
	Continua (medición)	Tiempo, memoria, monto, tarifa	FLOAT / DECIMAL	Descriptivas, percentiles, distribución

⚠ Una columna numérica puede ser **código de categoría** (1=Python, 2=Java): calcular su media **no tiene sentido**.

Escalas de medición

Escala	Característica	Ejemplo	Permite
Nominal	Clasifica sin ordenar	Lenguaje de programación	Contar, proporciones, moda
Ordinal	Clasifica y ordena	Nivel de satisfacción	Ordenar, contar, medidas de posición con cautela
Intervalo	Diferencias significativas, cero convencional	Temperatura °C	Diferencias y promedios
Razón	Cero absoluto	Tiempo, peso, monto	Diferencias y proporciones ("el doble")

Población, muestra y unidad de análisis

- **Población**: conjunto total de elementos a estudiar.
- **Muestra**: subconjunto (usar cuando estudiar todo es costoso/imposible); debe **representar** a la población o habrá sesgo.
- **Unidad de análisis**: cada elemento observado (generalmente cada **fila** del dataset).

Frecuencias

- **Absoluta (fi)**: cuántas veces aparece un valor. $\sum fi = n$.
- **Relativa (fr)**: $fr = fi / n (\times 100 = \text{porcentaje})$. Permite comparar grupos de distinto tamaño.

- **Acumulada:** cuántas observaciones son $\leq$ a un punto (solo con valores ordenados).
- **Datos agrupados:** para variables continuas o con muchos valores; intervalos [a, b) — incluye a, excluye b.
- **Marca de clase** = (límite inferior + límite superior) / 2.
- **Amplitud** = límite superior – límite inferior.
- Buenas prácticas: informar **porcentaje Y cantidad** (el % sin la base es engañoso).

Medidas de tendencia central

Medida	Fórmula/definición	Ventaja	Limitación
Media ($\bar{x}$)	$\bar{x} = \Sigma x_i / n$	Usa todos los valores	Sensible a outliers
Mediana	Valor central de los datos ordenados (si n par: promedio de los 2 centrales)	Resistente a extremos	No usa la magnitud de todos los valores
Moda	Valor/categoría más frecuente	Válida para categóricas	Puede haber varias o ninguna

Media vs. Mediana según el sesgo (¡clave para el examen!)

Situación	Forma	Qué usar
Media > Mediana	Asimetría positiva (cola a la derecha, outliers altos)	Mediana para el caso típico; media para impacto total/proyecciones
Media $\approx$ Mediana	Simétrica	Cualquiera, distribución equilibrada
Media < Mediana	Asimetría negativa (cola a la izquierda, valores bajos)	Mediana para ignorar anomalías bajas; media para medir pérdidas/impacto total

Medidas de posición

- **Cuartiles:** Q1 (25% debajo), **Q2 = mediana** (50%), Q3 (75% debajo).
- **Percentiles (Pk):** el k% de las observaciones queda por debajo. En tecnología se usan **P90, P95, P99** (tiempos de respuesta) porque un promedio aceptable puede ocultar casos muy malos.
- **Deciles:** dividen en 10 partes.

Medidas de dispersión

Medida	Fórmula	Nota
Rango	$R = x_{\max} - x_{\min}$	Fácil, pero depende de solo 2 valores
Varianza (s^2)	$s^2 = \Sigma (x_i - \bar{x})^2 / (n-1)$	Unidades al cuadrado
Desvío estándar (s)	$s = \sqrt{s^2}$	Misma unidad que la variable; pequeño = concentrados cerca de la media
Coef. de variación	$CV = (s / \bar{x}) \times 100$	Comparar dispersión relativa entre conjuntos con medias/unidades distintas
Rango intercuartílico (IQR)	$IQR = Q3 - Q1$	Dispersión del 50% central; resistente a outliers

Ejemplo: dos sistemas con media de 2s; desvío 0,2s (A, estable) vs 1,5s (B, variable). Mismo promedio, realidades distintas → **la media sola no alcanza**.

Parejas recomendadas: - Distribución simétrica sin extremos → **media + desvío estándar**. - Distribución asimétrica o con outliers → **mediana + IQR**. - Variable cualitativa → **moda/frecuencias + porcentajes**.

Boxplot (diagrama de caja) — anatomía

- **Caja:** de Q1 a Q3 (contiene el 50% central; ancho = IQR).
- **Línea central:** mediana (Q2).
- **Bigotes:** variabilidad esperada fuera de la caja (mín/máx válidos).
- **Puntos aislados: outliers** (anomalías).
- **Media** (punto/cruz): si se desvía de la mediana → **asimetría**.

Ejemplo (tarifas ADR de hoteles): City Hotel mediana 99 USD, IQR 47 (más caro, menos disperso); Resort mediana 75, IQR 76 (más disperso). Tarifas de 0 USD = cortesías o **errores a auditar** 🚩.

Valores atípicos (outliers)

- Pueden ser: error de carga, problema de medición, caso real excepcional o subgrupo distinto.
- **No eliminar automáticamente.** Preguntarse: ¿es posible en contexto? ¿es error? ¿caso excepcional? ¿subgrupo separado? ¿cambia la media/desvío? ¿su eliminación cambiaría la conclusión?

Errores frecuentes (checklist)

1. Confundir **códigos con cantidades** (media de categorías codificadas).
2. Informar la **media sin mirar mediana y extremos**.
3. Interpretar el **desvío sin la escala** (usar CV si corresponde).
4. **Porcentajes sin informar la base** (n).
5. Confundir **descripción con explicación** (correlación ≠ causalidad).
6. **Ignorar faltantes, duplicados o inconsistencias** antes de interpretar.

EDA — preguntas iniciales del análisis exploratorio

- ¿Cuántas observaciones y variables hay? ¿Qué representa cada fila?
- ¿Qué tipo de variable es cada columna? ¿Hay faltantes/duplicados?
- ¿Qué categorías son más frecuentes? ¿Cómo se distribuyen las numéricas?
- ¿Media ≈ mediana? ¿Hay outliers o subgrupos?
- ¿Qué medidas resumen mejor cada variable?

Caso aplicado en Power BI (dataset de reservas hoteleras, 25k registros, 32 variables)

- **Variable categórica** (`is_canceled`) → análisis de **frecuencias + gráfico de barras**: 62,96% efectivas vs 37,04% canceladas (oportunidad de retención).
 - **Variable cuantitativa** (`lead_time`) → media 102,6 / mediana 68,5 / moda 0 → **media > mediana = asimetría positiva** → la mediana es más representativa.
 - **Conclusiones clave:** combinar medidas (media + mediana + desvío) y visualizaciones; el tipo de variable determina la herramienta; en distribuciones asimétricas usar la mediana.
-



Repaso rápido (preguntas tipo)

1. ¿Diferencia entre dato e información? → El dato no tiene sentido semántico; la información son datos procesados y organizados que reducen incertidumbre.
2. ¿Los 4 tipos de análisis y su pregunta? → Descriptivo (¿qué pasó?), Diagnóstico (¿por qué?), Predictivo (¿qué pasará?), Prescriptivo (¿qué debería hacer?).
3. ¿Etapas del ETL y cuál es la más crítica? → Extraer, Transformar (la más crítica), Cargar.
4. ¿Diferencia Data Warehouse vs Data Lake? → DWH: datos estructurados, integrados, no volátiles, orientado al negocio. Lake: datos en bruto, cualquier formato; sin gobierno se vuelve Data Swamp.
5. ¿Los 4 pilares de un KPI? → Específico, Medible, Temporal, Relevante.
6. ¿Qué es un KR correcto? → Mide impacto (outcome), no tareas (output). Ej: "reducir cancelaciones del 14% al 5%".
7. ¿Diferencia entre "Agregar columna" y "Transformar" en Power Query? → Agregar **crea** una columna nueva; Transformar **modifica** la existente.
8. ¿Cómo corregir muchos valores mal escritos de forma mantenible? → Tabla de mapeo (staging) + Merge en Power Query.
9. ¿Cuándo usar mediana en vez de media? → Con asimetría o outliers (media > mediana = sesgo positivo).
10. ¿Fórmulas? → $f_r = f_i/n$; $\bar{x} = \sum x_i/n$; $s^2 = \sum (x_i - \bar{x})^2 / (n-1)$; $CV = s/\bar{x} \times 100$; $IQR = Q3 - Q1$.
11. ¿Qué mide el IQR y con qué medida se empareja? → Dispersión del 50% central; se usa con la **mediana** en distribuciones asimétricas.
12. ¿Qué hacer ante un outlier? → No eliminarlo automáticamente; investigar si es error, caso excepcional o subgrupo.