Introducción al Análisis de Datos

Clase 6 - Modelado de Datos

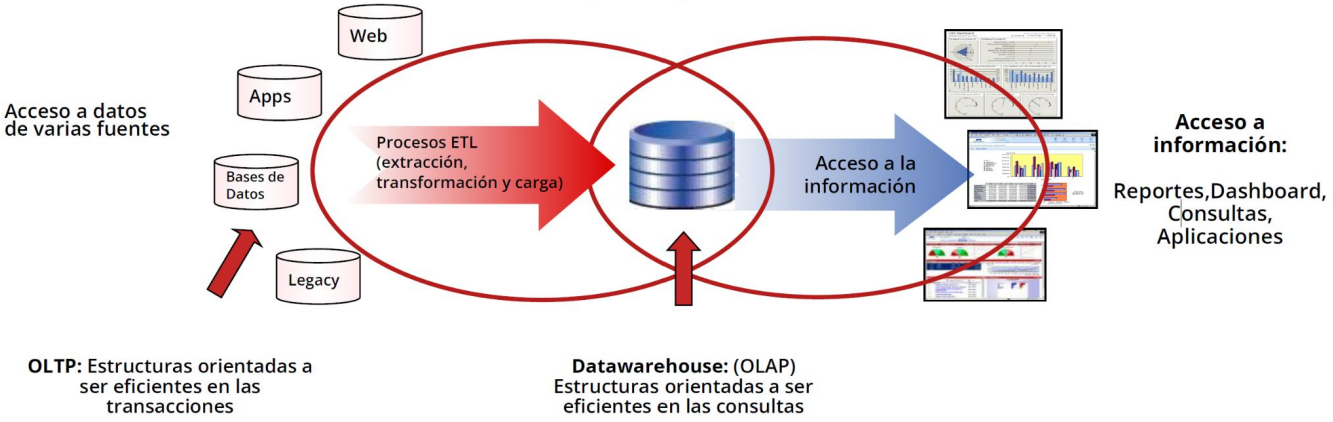
Índice

- ✓ Modelado de Datos en DWH
  - Modelo Estrella
  - Modelo Snowflake
- ✓ Modelado en Power BI
- ✓ Práctica Guiada

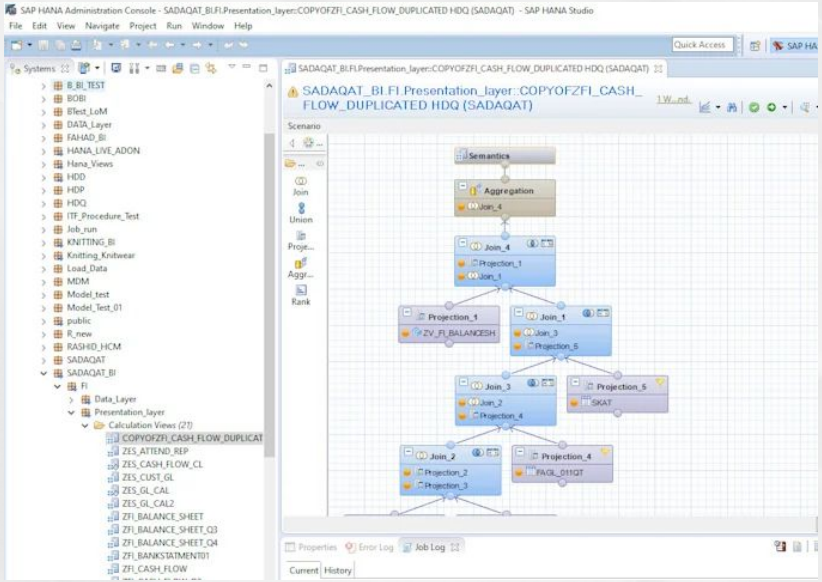
Modelado de Data Warehouse

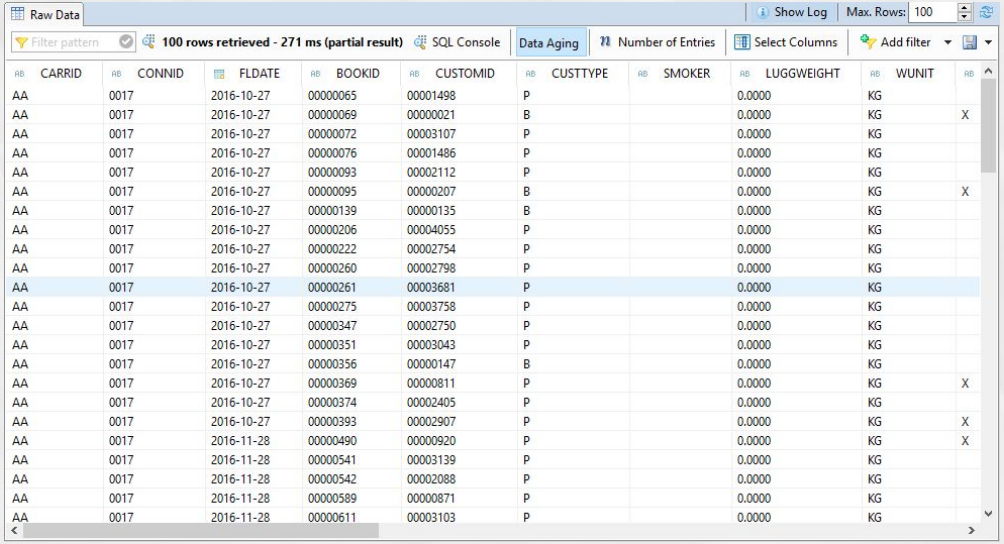
¿Qué es un Data Warehouse?

Es un **repositorio de datos** de muy fácil acceso, alimentado de **numerosas fuentes**, transformadas en grupos de información sobre temas específicos de negocios, para permitir nuevas **consultas, análisis, reportes y decisiones**.



¿Cómo se ve esto?



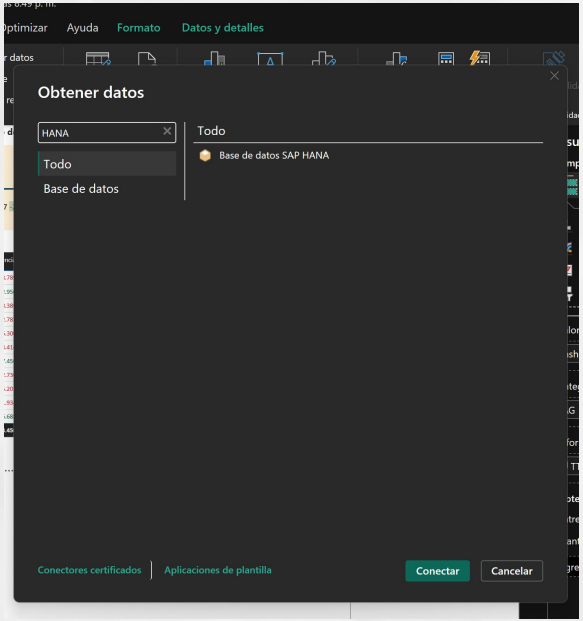


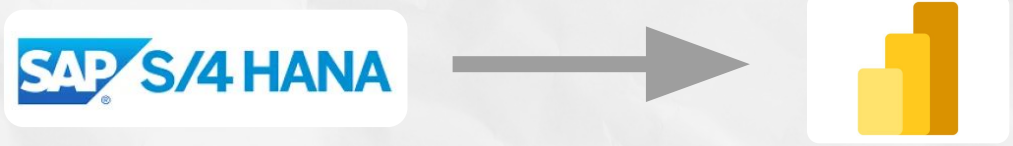
CARRID	CONNID	FLDATE	BOOKID	CUSTOMID	CUSTTYPE	SMOKER	LUGGWEIGHT	WUNIT	
AA	0017	2016-10-27	00000065	00001498	P		0.0000	KG	
AA	0017	2016-10-27	00000069	00000021	B		0.0000	KG	X
AA	0017	2016-10-27	00000072	00003107	P		0.0000	KG	
AA	0017	2016-10-27	00000076	00001486	P		0.0000	KG	
AA	0017	2016-10-27	00000093	00002112	P		0.0000	KG	
AA	0017	2016-10-27	00000095	00000207	B		0.0000	KG	X
AA	0017	2016-10-27	00000139	00000135	B		0.0000	KG	
AA	0017	2016-10-27	00000206	00004055	P		0.0000	KG	
AA	0017	2016-10-27	00000222	00002754	P		0.0000	KG	
AA	0017	2016-10-27	00000260	00002798	P		0.0000	KG	
AA	0017	2016-10-27	00000261	00003681	P		0.0000	KG	
AA	0017	2016-10-27	00000275	00003758	P		0.0000	KG	
AA	0017	2016-10-27	00000347	00002750	P		0.0000	KG	
AA	0017	2016-10-27	00000351	00003043	P		0.0000	KG	
AA	0017	2016-10-27	00000356	00000147	B		0.0000	KG	
AA	0017	2016-10-27	00000369	00000811	P		0.0000	KG	X
AA	0017	2016-10-27	00000374	00002405	P		0.0000	KG	
AA	0017	2016-10-27	00000393	00002907	P		0.0000	KG	X
AA	0017	2016-11-28	00000490	00000920	P		0.0000	KG	X
AA	0017	2016-11-28	00000541	00003139	P		0.0000	KG	
AA	0017	2016-11-28	00000542	00002088	P		0.0000	KG	
AA	0017	2016-11-28	00000589	00000871	P		0.0000	KG	
AA	0017	2016-11-28	00000611	00003103	P		0.0000	KG	

SAP S/4 HANA

¿Cómo se ve esto?

Finalizado mi ETL y almacenados los datos en el DWH, me conecto con mi herramienta de visualización **para comenzar el análisis.**





¿Qué es un modelo de datos?

Definición Abstracta

Un modelo de datos es un **modelo abstracto** creado con el objetivo de organizar elementos de datos y estandarizar las relaciones entre entidades del negocio.

Enfoque Estructural

Es la **estructura** que define las entidades de datos, sus relaciones y su implementación a partir de la naturaleza del negocio.

Gestión Correcta de Datos

Gestionar los datos correctamente ha constituido siempre una labor necesaria para disponer e integrar todos los datos que están esparcidos en el espacio, en una estructura **ordenada y limpia.**

El primer paso es crear un **modelado de datos** que permita realizar todas las operaciones que un manipulador de información requiere:

- **Almacenamiento**
- **Organización**
- **Tratamiento**
- **Procesamiento**

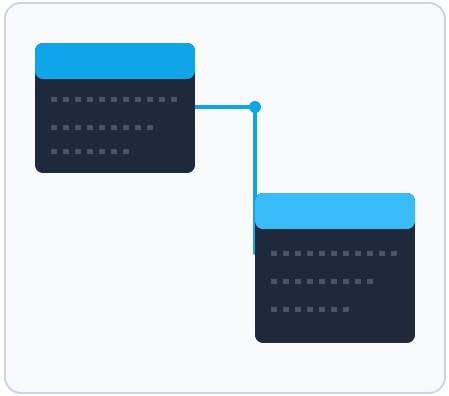


Modelos de Datos DW

Representación gráfica mediante diagramas entidad-relación para mostrar la estructura de tablas, campos y relaciones en Data Marts.

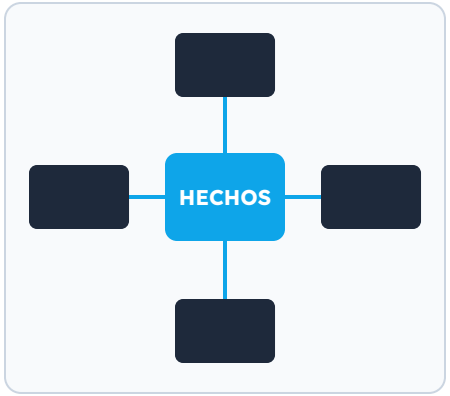
Diagrama Entidad-Relación

Muestra gráficamente las tablas, sus campos y las relaciones que existen entre ellas.



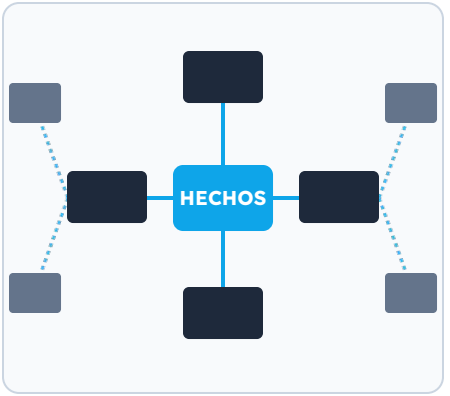
Modelo Estrella (Star)

Tabla de hechos central rodeada directamente por tablas de dimensiones simples.



Modelo Copo de Nieve

Estructura normalizada donde las dimensiones se ramifican en sub-dimensiones.



Modelos de Datos DW - Modelo estrella ⭐

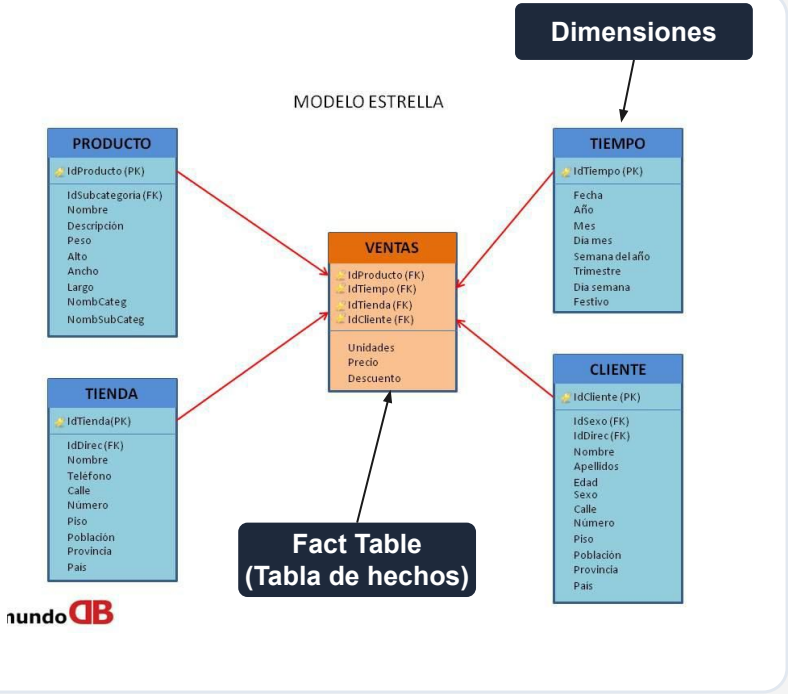
Características Principales

➔ Conexión Directa

Cada dimensión se conecta en forma directa con la tabla de hechos (Fact).

➔ Nivel Único de Relación

Hay un solo nivel para poder relacionar cualquier atributo de la dimensión con los datos de las fact table.



Modelos de Datos DW - Modelo Copo de nieve ❄️

Diseño Normalizado

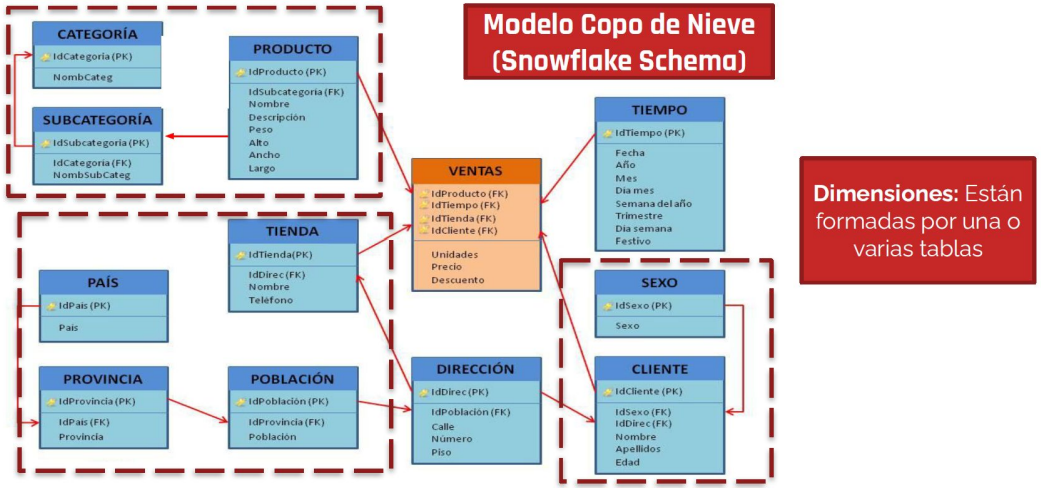
Las dimensiones están modeladas a partir de una o varias tablas con un diseño completamente normalizado. (1FN, 2FN, etc.)

Estructura Jerárquica

Las tablas de dimensiones se ramifican en sub-dimensiones o tablas secundarias.

Optimización de Espacio

Reduce la redundancia de datos almacenados en el Data Warehouse mediante la normalización.



Data Modeling en Power BI

Data Modeling en Power BI

➔Se realiza en el editor de consultas o **Query Editor**.

➔Establecimiento de las **conexiones de datos**.

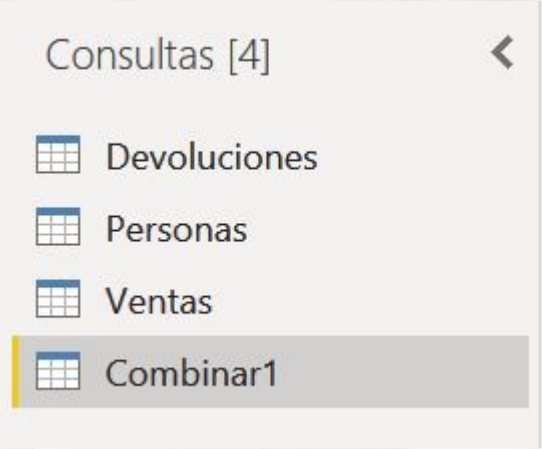
➔Validación y ejecución de tareas de **limpieza**.

➔**Combinación o Anexo** de tablas según su información.

➔Control de **carga a la capa Lógica** para optimización.



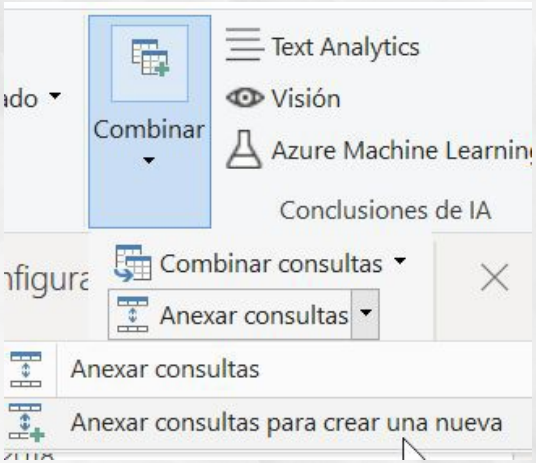
Power BI - Capa Física





En esta capa se pueden combinar los datos entre tablas usando uniones de filas (UNIONs o “Anexar Consultas”) o de columnas (JOINs o “Combinar Consultas”).

Power BI - Capa Física



Dentro del menú de Combinar encontraremos la opción de Anexar consultas y podremos elegir combinar una consulta a la consulta que tengamos seleccionada, o crear una consulta nueva con la combinación.

Power BI - Capa Lógica

Ubicación

Se lo realiza desde la pestaña de datos.

Validación de Estructura

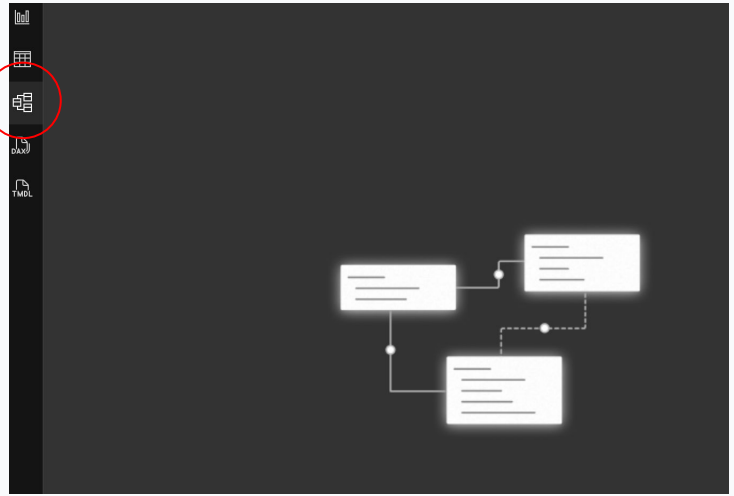
Se validan las tablas resultado y como son las relaciones entre ellas.

Checklist de Relaciones

- ¿Las columnas son las correctas?
- ¿La cardinalidad es la correcta?
- ¿Las direcciones de filtrado son correctas?

Optimización de Modelado

¿Se pueden crear tablas dimensionales que rompan las relaciones N a N?



Relación entre tablas

La relación entre ambas tablas y sus características, van a estar representados por **una línea, con un número o un asterisco** en sus extremos, así como una flecha que indica la dirección de filtrado.

*Cuando conectamos dos o más tablas al mismo tiempo, Power BI intenta detectar relaciones entre dichas tablas automáticamente. Busca identificar y configurar la **cardinalidad**, dirección de filtro cruzado y la activación de esas relaciones.*



La relación se establece a través de un campo que es **único**, es decir que es **CLAVE** en la tabla.

Cardinalidad

Uno a uno: cada registro en cada tabla solo aparece una vez

Cliente

N. Cliente	Nombre	Sexo	Telefono	ID_ EDAD
398	Cristian	M	45786349	1
562	Fernando	M	42568360	3
817	Silvana	F	32583159	5
345	Juan	M	34484056	8
390	Mariela	F	45835000	9

1 — 1

Edad

ID_ EDAD	EDAD
1	25
3	64
5	43
8	30
9	14

Uno a muchos: un registro en una tabla puede tener relación con varios elementos de otra tabla

Cliente

N. Cliente	Nombre	Sexo	Telefono	ID_ EDAD
398	Cristian	M	45786349	1
562	Fernando	M	42568360	3
817	Silvana	F	32583159	5
345	Juan	M	34484056	8
390	Mariela	F	45835000	9

1 — *

Ventas

N. Cliente	Folio	Clave	Cantidad	Total	Subtotal	Iva
398	3	9	27	4367	369	19%
562	35	12	63	915	536	6%
817	185	5	17	5749	927	20%
345	15	82	22	24	3	2%
390	39	11	18	512	74	10%
817	542	36	65	9472	327	21%

Cardinalidad

Muchos a muchos: Cuando uno o más registros en una tabla puede tener una relación con uno o más elementos de otra tabla.

Ventas

N. Cliente	Folio	Clave	Cantidad	Total	Subtotal	Iva
398	3	9	27	4367	369	19%
562	35	12	63	915	536	6%
817	185	5	17	5749	927	20%
345	15	82	22	24	3	2%
390	39	11	18	512	74	10%
817	542	36	65	9472	327	21%

* *

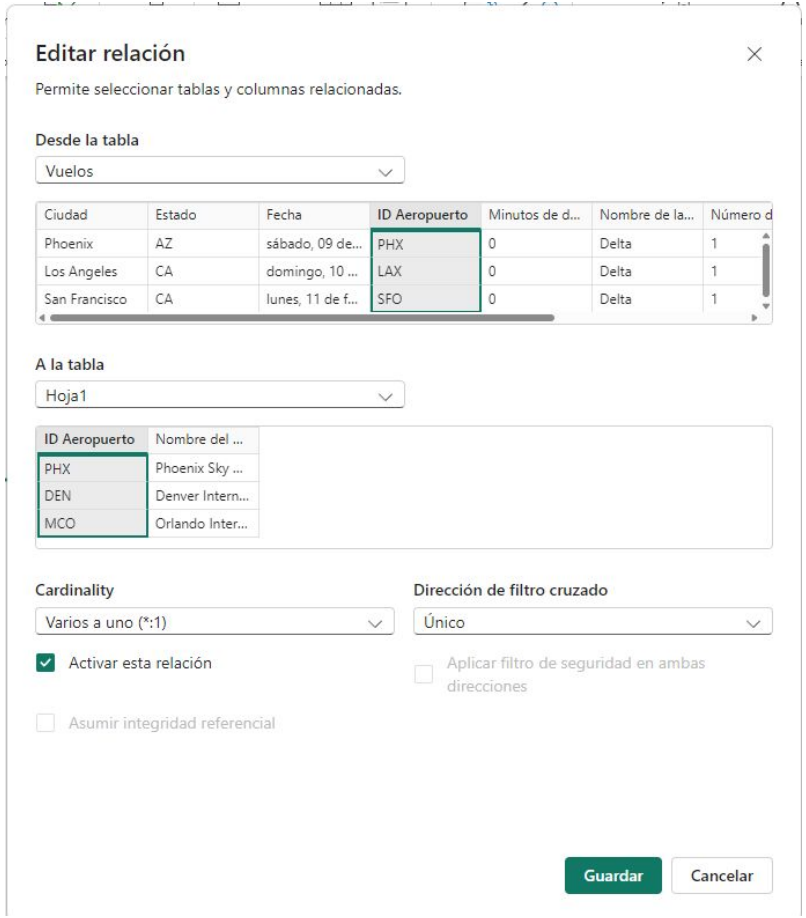
Productos

Clave	Descripcion	P. Unitario	Existencias
9	Escritorios	35	4
12	Sillas	43	9
5	Ipad Mouse	75	5
82	Microfonos	95	2
11	Parlantes	23	1
11	Parlantes	52	8

Editar relaciones

Power BI permite editar las relaciones establecidas de forma automática.

Ingresando al editor de relaciones, podemos ver entre qué columnas se creó la relación, qué tipo de cardinalidad tiene, la dirección y si la relación está activa.



Tablas Dimensionales

Las tablas dimensionales permiten **homogeneizar los datos** de manera eficiente.



Maestros de Datos

Permiten mostrar los datos de las columnas dimensionales de una única forma dentro de todo el tablero, garantizando consistencia.



Relaciones Complejas

Son fundamentales cuando la relación entre dos tablas requiere más de una columna, superando las limitaciones estándar de Power BI.

MODELADO DE DATOS

¿Qué debemos preguntarnos sobre estos datos?

DIMENSIONES (ENTIDADES)

DIM_Fechas

Día
Semana
Mes
Año
Hora

DIM_Clientes

ID Cliente
Nombre
Canal de venta

DIM_Transportes

ID Vehículo
Matrícula
Vehículo

DIM_Empleados

ID Empleado
Antigüedad
Tarea

DIM_Productos

ID Producto
Nombre
Unidad de Medida
Precio Unitario

HECHOS (EVENTOS)

FACT_Ventas

ID Factura
Fecha
ID Producto
ID Cliente
Importe total

Resumen: Típica estructura de modelo de datos dividida en **Dimensiones** y **Hechos**.

Modelado de datos

Práctica Guiada

Práctica Guiada

CONTEXTO

El Caso de Negocio: "SoundStream"

Una plataforma de streaming de música nos pide diseñar su base de datos analítica y su primer tablero de control ejecutivo. Hoy tienen un sistema transaccional donde se registran millones de reproducciones diarias. Nos entregan los siguientes datos e inquietudes:

Registran cada reproducción con su fecha, hora, usuario, canción, artista, género y la sucursal de suscripción del usuario.

Quieren ver la evolución de horas reproducidas mes a mes.

Necesitan un ranking con los 5 artistas más escuchados para motivar acuerdos comerciales.

El gerente de Marketing sospecha que los usuarios que tienen cuentas "Free" (con publicidad) abandonan la reproducción a la mitad, y quiere ver la correlación entre la duración de la canción y el porcentaje de avance del usuario.

Desafío Analítico: Identificar Dimensiones y Hechos para responder a las preguntas de negocio.

Fin