

<https://www.youtube.com/watch?v=7fb6gtwj5X0&t=247s>

Este video explica de forma sencilla qué es el Web Scraping. Muy interesante para ver.

Web Scraping es la técnica para extraer datos de páginas web de forma automatizada. No es ilegal pero hay muchas empresas que no quieren que se accedan a sus datos de esta forma, por eso utilizan las medidas de seguridad contra bots llamada "CAPTCHA" (Completely Automated Public Turing test to tell Computers and Humans Apart)

El scraper le pide un request a la URL, simulando lo que hace una persona real mediante un navegador -> el servidor le devuelve el HTML de la página -> se recorre esa respuesta usando el DOM u otras herramientas para encontrar los datos deseados -> se toman los valores específicos (texto dentro de un <div>) -> los datos se guardan en un archivo (JSON, XML, CSV, etc) -> se repite el proceso si hay muchas páginas para buscar información.

Se utilizan lenguajes como Python, Node, JS, C#, entre otros. Las herramientas más conocidas son Puppeteer, Selenium, Scrapy y BeautifulSoup.

La página estática viene con la información en el HTML inicial, por ende el scraper puede realizar su procedimiento saltando el primer paso (simular una persona real en un navegador), es decir; hace el GET y ya obtiene la información.

La página dinámica tiene su HTML vacío, y recién se carga cuando el JS identifica un navegador real (aca entran las herramientas como

Selenium y Puppeteer). Cuando carga el navegador entero ya puede obtener la información.

La carpeta “WebScrapingEjemplo” tiene un código básico de una url pública y estática, listo para ejecutar.